

BigDataSmallPrice: Automatisierte Prognose dynamischer Stromtarife für Winterthur mittels Machine Learning

Ryan Bachmann
ZHAW School of Engineering
Winterthur, Schweiz

Dinis Silva Miguel
ZHAW School of Engineering
Winterthur, Schweiz

Gian Ruchti
ZHAW School of Engineering
Winterthur, Schweiz

Zusammenfassung

Mit den neuen Schweizer Strommarktregeln werden dynamische Tarifmodelle ab 2026 für Netzbetreiber und Endkunden deutlich relevanter. Für Haushalte und Unternehmen bedeutet das eine grosse Chance: Wer weiss, wann Strom günstig ist, kann Waschmaschine, Wärmepumpe oder E-Auto gezielt zu diesen Zeiten betreiben und bis zu 40 % Kosten sparen. Das Problem: Bisher gibt es keine öffentlich zugängliche Prognose, die mehrere Tage im Voraus zeigt, wann der Strom billig oder teuer wird.

Wir lösen dieses Problem mit *BigDataSmallPrice*, einer vollständig automatisierten Plattform, die täglich Daten aus acht Quellen (darunter europäische Energiebörsendaten, Wetterprognosedaten und den historischen Lastgang der Stadt Winterthur) zusammenführt und daraus eine 7-Tage-Tarifprognose im 15-Minuten-Raster berechnet. Zwei XGBoost-Modelle prognostizieren jeweils den Netznpreis (basierend auf der lokalen Stromnachfrage) und den Energiepreis (basierend auf den europäischen Börsenpreisen). Mit einem mittleren Fehler von 3,99 % beim Lastmodell und 7,72 % beim Preismodell liegen beide deutlich unter den gesetzten Qualitätszielen. Die Prognosen werden über ein interaktives Dashboard mit Ampelindikator und persönlichen Verbrauchsempfehlungen angezeigt.

1 Einleitung

Die Schweizer Energieversorgung befindet sich im Umbruch. Mit dem revidierten Stromversorgungsgesetz und der ab 2026 wirkenden Tarifregulierung werden dynamische Netznutzungstarife regulatorisch ermöglicht und von ersten Versorgern als Wahltarif eingeführt [1, 3]. Gleichzeitig steigt die Zahl steuerbarer Geräte in Schweizer Haushalten rasant: Der Marktanteil von Elektrofahrzeugen überstieg 2024 die 25-Prozent-Marke, und Wärmepumpen ersetzen zunehmend Heizölanlagen [2]. Das Zusammenspiel von dynamischen Tarifen und steuerbaren Lasten eröffnet ein erhebliches Einsparpotenzial von bis zu 40 % gegenüber dem Fixpreis, wenn der Verbrauch in Schwachlastzeiten verschoben wird [3].

Die Herausforderung besteht darin, dass Endkunden diese Einsparungen nur dann gezielt nutzen können, wenn sie *im Voraus* wissen, wann Strom günstig oder teuer sein wird. Bisherige Ansätze zur Strompreisvorhersage aus der Forschung [4, 6] fokussieren meist auf europäische Börsenpreise, nicht aber auf die konkrete Tarifzusammensetzung, die Endkunden auf der Rechnung sehen. Kommerzielle Portale wie jenes der EKZ [3] zeigen historische und aktuelle Tarife, liefern aber keine Prognosen für die kommenden Tage.

Beiträge dieser Arbeit. Wir präsentieren *BigDataSmallPrice* mit folgenden Beiträgen:

- (1) Eine vollautomatische Datenpipeline, die täglich Daten aus acht Quellen einliest, bereinigt und in einer Zeitreihendatenbank speichert.
- (2) Zwei kalibrierte Vorhersagemodelle für Netz- und Energiepreis mit nachvollziehbarem Retraining und messbaren Genauigkeitszielen.
- (3) Transparente Tarifformeln, die Rohergebnisse in konkrete Rp./kWh-Werte mit Unsicherheitsgrenzen umrechnen.
- (4) Ein Nutzerdashboard mit Wochenprognose, Ampelindikator und gerätespezifischen Empfehlungen sowie eine offene REST-Schnittstelle für Drittsysteme.

2 Hintergrund und Problemstellung

2.1 Dynamische Stromtarife in Winterthur

Die EKZ (Elektrizitätswerke des Kantons Zürich) veröffentlichen seit 2024 zwei dynamische Tarifprodukte im 15-Minuten-Raster: einen *Netznpreis* (abhängig davon, wie stark das lokale Stromnetz gerade belastet ist) und einen *Energiepreis* (gekoppelt an den EPEX-Spot-Day-Ahead-Markt, auf dem europäische Stromproduzenten und -verbraucher handeln). Der Gesamttarif, den Kunden zahlen, ergibt sich als Summe:

$$T_{\text{gesamt}}(t) = T_{\text{netz}}(t) + T_{\text{energie}}(t) \quad [\text{Rp./kWh}] \quad (1)$$

In der Praxis schwankt dieser Gesamttarif zwischen rund 12 und 28 Rp./kWh, ein Faktor von über zwei zwischen gutem und schlechtem Zeitpunkt. EKZ veröffentlicht die Tarife in der Regel erst am Vortag, was für eine mehrtägige Verbrauchsplanung nicht ausreicht.

2.2 Datengrundlage

Tabelle 1 fasst alle acht integrierten Datenquellen zusammen. Die Grundlage für die Lastprognose bildet der Winterthurer Bruttolastgang (OGD #1863): 15-minütige Strommessungen seit 2013, insgesamt rund 462 000 Datenpunkte. Die Energiepreisvorhersage basiert auf ENTSO-E-Day-Ahead-Preisen seit 2015. Als Wetterdaten nutzen wir die kostenlose Open-Meteo-API für Winterthur und zwei deutsche Referenzstationen, da norddeutsches Windaufkommen erfahrungsgemäss den grössten Einfluss auf europäische Strompreise hat [4]. EKZ-, CKW- und Groupe-E-Tarife werden täglich abgerufen und dienen als Vergleichsreferenz zur Kalibrierung und Validierung.

2.3 Explorative Datenanalyse

Abbildung 1 zeigt zwei zentrale Muster aus den Rohdaten. **Links:** Das mittlere Lastprofil pro Stunde des Tages unterscheidet sich deutlich zwischen Werktagen und Wochenenden. An Werktagen entstehen zwei ausgeprägte Spitzen: eine morgens (7–9 Uhr) und eine abends (18–21 Uhr), während die Last zwischen 1 und 5 Uhr auf rund 55 % des Tagesmaximums fällt. Am Wochenende ist das

Tabelle 1: Integrierte Datenquellen

Quelle	Inhalt	Takt	Format
ENTSO-E (A44/A65/A75/A11/A01)	Preise, Last, Erzeug., Flüsse	15 min / 1 h	REST / XML
Open-Meteo (CH + DE)	Temp., Wind, Solar, Wolken	1 h	REST / JSON
OGD Winterthur #1863	Bruttolastgang	(ab 15 min 2013)	CSV / API
OGD Winterthur #3122	PV-Einspeisung	15 min	CSV / API
EKZ-Tarif-API	Referenztarif (Netz+Energie)	15 min	REST / JSON
CKW-Tarif-API	Vergleichstarif Inner-schweiz	15 min	REST / JSON
Groupe E-API	Vergleichstarif mandie	Ro- 15 min	REST / JSON
BAFU Hydrologie	Reservoir, Durchfluss	täglich	CSV




Abbildung 1: Links: mittleres Tageslastprofil für Werktag und Wochenenden (normiert auf das Tagesmaximum der Werktag). Rechts: Verteilung der EPEX-Day-Ahead-Stundenpreise 2015–2025; der Median liegt bei ≈65 EUR/MWh, rund 4 % der Werte sind negativ.

Profil flacher und die Abendspitze weniger stark. Diese regelmäßigen Muster sind der Hauptgrund, warum Zeitmerkmale (Stunde, Wochentag, Kalenderfeiertage) die wichtigsten Eingabevariablen für Modell A sind. **Rechts:** Die EPEX-Stundenpreise zeigen eine rechtsschiefe Verteilung mit einem Median von rund 65 EUR/MWh und einem langen rechten Ausreisser-Schwanz in Richtung hoher Preise. Negative Preise (Überschuss an erneuerbaren Energien) treten in rund 4 % aller Stunden auf und werden durch die Tarifformel bei 0 Rp./kWh begrenzt.

2.4 Aufgabenstellung

Das Ziel ist, auf Basis aller bis zum heutigen Tag bekannten Informationen (vergangene Lastmessungen, publizierte Börsenpreise, Wettervorhersagen und Kalendermerkmale) eine Prognose für die nächsten sieben Tage (672 Zeitschritte à 15 Minuten) zu erstellen. Dafür werden zwei separate Vorhersagen benötigt: erstens die künftige Nettolast im Winterthurer Netz (Grundlage des Netzpreises), und zweitens der künftige EPEX-Day-Ahead-Preis (Grundlage des Energiepreises). Aus diesen beiden Prognosen berechnen kalibrierte Tarifformeln (vgl. Abschnitt 3.4) den erwarteten Gesamttarif in Rp./kWh.

3 Systemdesign

3.1 Gesamtarchitektur

Das System besteht aus fünf Schichten (Abbildung 2), die als Docker-Compose-Stack auf einer lokalen Workstation laufen. Jede Schicht kommuniziert über klar definierte Schnittstellen mit der nächsten, sodass einzelne Teile unabhängig aktualisiert werden können.




Abbildung 2: Systemarchitektur von BigDataSmallPrice (5 Schichten, Docker-Compose-Stack).




Abbildung 3: Projektstruktur: Die Ordner spiegeln den Datenfluss von Orchestrierung über Speicherung und Modellierung bis zur API und zum Dashboard wider.

3.2 Datenpipeline und Orchestrierung

Die Datenerfassung ist in vier Apache-Airflow-Workflows (DAGs) organisiert (Abbildung 3 ordnet die wichtigsten Codebereiche ein):

- **ETL-Pipeline:** Lädt täglich ab 06:00 UTC Daten von allen acht Quellen mit parallelen Fetch-Tasks herunter, jeweils nach Veröffentlichung der ENTSO-E-Day-Ahead-Daten.
- **Feature-Pipeline:** Berechnet aus den Rohdaten die Eingabevariablen für das Training und exportiert sie als Parquet-Dateien.
- **Training-Pipeline:** Wird über Airflow oder das Admin-Dashboard ausgelöst, bewertet die Modelle auf einem Validierungsset und speichert das jeweils beste Modell.
- **Backfill-Pipeline:** Ermöglicht das nachträgliche Einlesen historischer Daten, wenn eine neue Quelle hinzugefügt wird.

Abbildung 4 zeigt die vereinfachte Abhängigkeitsstruktur der täglichen Daten- und Feature-Verarbeitung sowie den manuellen Training-Trigger.




Abbildung 4: Vereinfachter Airflow-DAG: Die Fetch-Tasks laufen parallel; anschliessend werden Daten validiert, in TimescaleDB gespeichert, Features exportiert und Modelle bei Bedarf neu trainiert.

Alle Rohdaten werden in TimescaleDB gespeichert, einer PostgreSQL-Erweiterung für Zeitreihendaten. Dank automatischer Chunk-Partitionierung skaliert die Datenbank problemlos auf Milliarden von Zeitpunkten. Interne Aggregationsviews fassen 15-Minuten-Daten auf Stundenebene zusammen, was Trainingsabfragen um Faktor 4–8 beschleunigt.

3.3 Eingabevariablen (Features)

Für die beiden Modelle werden unterschiedliche Eingabevariablen verwendet:

Modell B: Energiepreis (41 Variablen): Kern sind Vergangenheitswerte des EPEX-Preises von vor 1 Stunde, 24 Stunden und 7 Tagen, ergänzt durch gleitende Durchschnitte. Stunde des Tages, Wochentag und Monat werden als Sinus/Kosinus-Wertepaare kodiert, damit das Modell die tägliche und jährliche Periodizität korrekt erfasst. Wetterdaten (Temperatur, Wind, Sonnenstrahlung) für Winterthur sowie norddeutsche Windmessungen ergänzen das Bild, da viel Wind in Norddeutschland die europäischen Strompreise stark drückt. Zusätzlich fließen ENTSO-E-Erzeugungsdaten (Wasser-, Solar-, Windkraft) und die am Vortag publizierte europaweite Lastprognose ein.

Modell A: Nettolast (24 Variablen): Hier stehen Kalendermerkmale (Stunde, Wochentag, Monat, Quartal), Feiertags- und Schulferienindikatoren für den Kanton Zürich sowie Wettervariablen im Vordergrund. Vergangenheitswerte der Last von vor 1 Stunde, 24 Stunden und 7 Tagen ermöglichen dem Modell, wiederkehrende Tagesmuster zu erkennen. Die Nettolast ergibt sich aus dem Bruttolastgang (OGD #1863) abzüglich der PV-Einspeisung (OGD #3122).

3.4 Tarifformeln

Die vorhergesagte Nettolast wird auf den historischen Schwankungsbereich normiert. Als robuste Grenzen verwenden wir das 5. und 95. Perzentil: 6 000 kWh und 17 500 kWh.

$$\hat{L}_{\text{norm}} = \frac{\hat{L} - 6000}{17500 - 6000} \in [0, 1] \quad (2)$$

Daraus berechnet sich der Netzpreis durch eine lineare Formel mit Ober- und Untergrenze:

$$T_{\text{netz}} = \text{clip}\left(11,0 + 6,0 \cdot \hat{L}_{\text{norm}}, 8,0, 14,0\right) \quad (3)$$

Die Einheit aller Tarifwerte ist Rp./kWh. Eine quadratische Formel wurde geprüft, führte aber dazu, dass 60 % aller Zeitpunkte im mittleren Lastbereich denselben Tarifwert erhielten, was für Nutzer keine sinnvolle Differenzierung ermöglicht. Der Energiepreis wird

als linearer Durchleitwert des Börsenpreises berechnet (kalibriert per Regression auf EKZ-Referenzdaten):

$$T_{\text{energie}} = \text{clip}\left(0,226 \cdot \frac{\hat{P}_{\text{EPEX}}}{10} + 7,0, 4,0, 14,0\right) \quad (4)$$

Unsicherheitsbereiche werden als $\pm 1,96 \cdot \hat{\sigma}$ mitgegeben, wobei $\hat{\sigma}$ der durchschnittliche Vorhersagefehler auf dem Validierungsset ist.

3.5 Vorhersagemodelle

Für beide Zielgrössen wurden vier Modellvarianten trainiert und verglichen:

- (1) **Naive-Baseline:** Sagt für jeden Zeitpunkt einfach den historischen Mittelwert voraus und dient als untere Messlatte.
- (2) **Lineares Modell:** Berechnet eine gewichtete Summe aller Eingabevariablen (mit Auffüllung fehlender Werte durch den Median).
- (3) **XGBoost:** Gradient-Boosting-Modell, das Hunderte von Entscheidungsbäumen kombiniert. Es kann nichtlineare Zusammenhänge lernen, kommt mit fehlenden Werten um und trainiert in wenigen Minuten. Dies ist das eingesetzte Produktionsmodell.
- (4) **LSTM und Transformer:** Neuronale Netze, die explizit zeitliche Abhängigkeiten in langen Sequenzen modellieren (Fenster von 24 h für die Last, 48 h für den Preis). Sie dienen als Vergleich und können optional auf der GPU trainiert werden.

Das nach dem Validierungsfehler beste Modell wird automatisch als Produktionsmodell registriert und für alle Prognosen verwendet.

3.6 Dashboard und Schnittstelle

Das Nutzer-Dashboard zeigt den aktuellen Stromtarif mit einem Ampelindikator (grün/gelb/rot) sowie eine interaktive 7-Tage-Kurve. Günstige 2-Stunden-Zeitfenster für flexible Lasten werden automatisch hervorgehoben. Über ein Gerätereister (Waschmaschine, E-Fahrzeug, Wärmepumpe) erhält der Nutzer persönliche Empfehlungen. Das Admin-Dashboard war während der gesamten Entwicklung ein zentrales Werkzeug und zeigte auf einen Blick alle systemkritischen Kennzahlen: MAE und MAPE beider Modelle (aktuell und historisch), Zeitpunkt des letzten erfolgreichen Trainings, Datenfrische je Quelle (wann zuletzt aktualisiert), Laufhistorie und Erfolgsstatus jedes Airflow-DAG-Runs sowie Alert-Indikatoren bei veralteten oder fehlenden Daten. Ohne diese Übersicht wäre es kaum möglich gewesen, rasch zu erkennen, wann eine externe API aussetzte oder ein Modell-Retraining stillschweigend einen schlechteren MAPE produzierte. Die REST-Schnittstelle stellt über 40 Endpunkte bereit, darunter die 7-Tage-Prognose mit Konfidenzbändern, Modellmetriken, Datenbankstatus und manuelle Pipeline-Trigger.

3.7 Big-Data-Aspekte

Das Projekt adressiert alle fünf klassischen Dimensionen von Big Data.

Datenmenge (Volume): Die TimescaleDB-Instanz speichert aktuell rund 1,5 Mio. Zeitreihenpunkte aus acht Quellen. Der Winterthurer Bruttolastgang allein umfasst 13 Jahre a 96 Messungen pro Tag (462 000 Einträge), die ENTSO-E-Feeds steuern weitere

rund 500 000 Stundenwerte bei. Täglich kommen etwa 300 neue Zeilen hinzu. Trainingsabfragen aggregieren diese Masse mit SQL-Fensterfunktionen direkt in der Datenbank; für Modell A werden rund 315 000 Trainingspunkte mit je 24 Features in einer Parquet-Datei bereitgestellt (≈ 60 MB unkomprimiert). TimescaleDB partitioniert die Hypertabellen automatisch in 7-Tage-Zeitblöcke und komprimiert ältere Chunks auf rund 15 % der Originalgrösse, sodass die Gesamtlösung auf Milliarden von Einträgen skaliert.

Aktualität (Velocity): Die ETL-Pipeline läuft täglich um 06:00 UTC; eine Stunde später erzeugt die Feature-Pipeline neue Parquet-Exporte. Das Training wird bei Bedarf über das Admin-Dashboard oder Airflow gestartet. Der 7-Tage-Prognose-Endpunkt liefert 672 Zeitpunkte mit Tarifkomponenten; ein 15-Minuten-Cache verhindert wiederholte Datenbankabfragen für identische Dashboard-Anfragen.

Datenvielfalt (Variety): Das System verarbeitet sechs Datenformate (REST/JSON, REST/XML, CSV-Download, Parquet, SQL-Views, serialisierte Modelldateien) von acht unabhängigen Quellen mit zeitlichen Auflösungen zwischen 15 Minuten (Lastgang, ENTSO-E) und 1 Tag (BAFU-Hydro). Ein zentraler Alignment-Schritt synchronisiert alle Quellen auf ein einheitliches 15-Minuten-Raster; fehlende Werte werden quellspezifisch mit Median-Imputation oder Vorwärtsfüllung aufgefüllt.

Datenqualität (Veracity): Jede Datenquelle durchläuft nach dem Download einen Validierungsschritt: Bereichsprüfung (Lastgang > 0 , Preise > -500 EUR/MWh), Vollständigkeitsprüfung (maximal 5 % fehlende Werte pro Tag erlaubt) und Plausibilitätsprüfung gegen den gleitenden Median der letzten 7 Tage. Datensätze, die diese Checks nicht bestehen, lösen einen Airflow-Alert aus und werden nicht für das Training verwendet. Dieser Schritt war entscheidend, da mehrere Quellen gelegentlich inkonsistente oder verzögerte Daten lieferten.

Parallelisierung (Value & Processing): Die ETL-Pipeline führt bis zu 14 Fetch-Tasks gleichzeitig aus, was die Gesamtlaufzeit gegenüber sequenzieller Verarbeitung von über 20 auf unter 8 Minuten reduziert. XGBoost nutzt alle CPU-Kerne des i9-Prozessors (16 logische Kerne) für das parallele Baum-Training. Die neuronalen Netze können optional auf einer NVIDIA RTX 3080 GPU trainiert werden, was die Trainingszeit für LSTM und Transformer gegenüber reiner CPU-Berechnung um den Faktor 8–12 verkürzt.

4 Experimentelle Evaluation

4.1 Versuchsaufbau

Alle Experimente liefen auf einer lokalen Workstation (Intel Core i9, 32 GB RAM, NVIDIA RTX 3080 mit 10 GB VRAM) unter Python 3.11 in Docker-Containern. Die Daten wurden *chronologisch* aufgeteilt, damit das Modell nie “in die Zukunft schaut”:

- **Modell A (Last):** Training auf 2013–2022 (≈ 315 000 Datenpunkte), Validierung 2023, Test 2024–2025.
- **Modell B (EPEX-Preis):** Training Jan 2024 bis Jan 2026, Validierung Feb/Mär 2026, Test ab Apr 2026.

Als Hauptkennzahl verwenden wir den *MAPE* (mittlerer absoluter prozentualer Fehler), der angibt, um wie viel Prozent das Modell im Schnitt daneben liegt. Zusätzlich berichten wir MAE (absoluter Fehler in der jeweiligen Einheit) und RMSE (strafft grosse Einzelfehler stärker). Für den EPEX-Preis werden Zeitpunkte mit Preisen

Tabelle 2: Modellvergleich auf den Testmengen (Stand: 06.05.2026)

	Methode	MAE	RMSE	MAPE
<i>Modell A: Nettolast [kWh/15 min]</i>				
Naive	Mittelwert	4 065	5 042	56,9 %
Linear	Lin. Regression	362	580	3,75 %
LSTM	2-Layer LSTM	541	784	5,62 %
Transformer	Encoder-Transf.	566	771	5,93 %
XGBoost	Gradient Boosting	303	459	3,99 %
<i>Modell B: EPEX-Preis [EUR/MWh]</i>				
Naive	Mittelwert	45,5	56,9	43,7 %
Linear	Lin. Regression	8,7	15,5	9,9 %
LSTM	2-Layer LSTM	14,2	24,9	16,9 %
XGBoost	Gradient Boosting	6,9	15,4	7,72 %

unter 10 EUR/MWh aus der MAPE-Berechnung ausgeklammert, da sehr kleine Werte den Prozentwert künstlich aufblasen würden. Qualitätsziele: MAPE ≤ 8 % (Modell A), MAPE ≤ 15 % (Modell B).

4.2 Ergebnisse

Tabelle 2 zeigt die Ergebnisse aller Modellvarianten auf dem jeweiligen Testset. XGBoost ist in beiden Fällen die beste Variante und erreicht die gesetzten Qualitätsziele deutlich. Interessant: Das lineare Modell schneidet bei der Lastprognose kaum schlechter ab als XGBoost, ein Zeichen, dass der Lastgang stark von linearen Grössen wie Tageszeit und Temperatur getrieben wird. Bei den EPEX-Preisen sind die Nichtlinearitäten grösser: Hier liegt das lineare Modell mit 9,9 % deutlich hinter XGBoost mit 7,72 %.

Abbildung 5 zeigt eine typische 7-Tage-Prognose: Wöchentliche Spitzen am Morgen und Abend, ein Mittagstief durch solare Einspeisung sowie ein deutlich ruhigeres Wochenende sind gut erkennbar.




Abbildung 5: Beispielhafte 7-Tage-Tarifprognose mit Ampelzonen (grün ≤ 17 , gelb 17–22, rot ≥ 22 Rp./kWh) und 95%-Konfidenzband. Deutlich erkennbar: morgendliche und abendliche Preisspitzen an Werktagen sowie ein ruhigeres Wochenende (Sa/So).

4.3 Welche Eingabevariablen sind am wichtigsten?

Bei Modell B (Energiepreis) sind die wichtigsten Variablen der gestrige und der vorwochentliche Preis sowie die veröffentlichte

europäische Lastprognose. Bei Modell A (Nettolast) dominieren der Verbrauch von gestern und vor einer Woche, zusammen mit der Tageszeit. Die Sinus/Kosinus-Kodierung der Zeitvariablen verbessert die Genauigkeit gegenüber einer einfachen Ganzzahlkodierung um 1–3 Prozentpunkte, da so die tägliche und wöchentliche Periodizität explizit im Modell abgebildet wird. Die BAFU-Hydrodaten erwiesen sich als wenig hilfreich, weil tagesaktuelle Reservoirmesswerte für eine Day-Ahead-Prognose strukturell zu spät ankommen.

4.4 Systemleistung

Der API-Endpunkt für die 7-Tage-Prognose liefert 672 Datenpunkte mit Tarifformeln und Unsicherheitsgrenzen. Da das Dashboard identische Prognoseabfragen für 15 Minuten cacht, muss die Datenbank bei wiederholten Aufrufen nicht erneut belastet werden.

5 Diskussion

5.1 Was gut funktioniert hat

TimescaleDB hat sich als ideale Wahl für den Datenspeicher erwiesen. Da es auf PostgreSQL aufbaut, können wir direkt in der Datenbank komplexe Abfragen für das Feature Engineering schreiben, ohne separate Verarbeitungswerkzeuge. Die automatische Aggregation von 15-Minuten- auf Stundendaten beschleunigt Trainingsabfragen erheblich.

XGBoost als Produktionsmodell bestätigt den Befund aus der Literatur [4]: Gradient-Boosting-Verfahren übertreffen bei tabellari-schen Daten mit gemischten Variablentypen und fehlenden Werten häufig neuronale Netze, besonders wenn die Trainingsdatenmenge begrenzt ist.

Apache Airflow hat die tägliche Zuverlässigkeit der Pipeline sichergestellt. Durch die explizite Abhängigkeitssteuerung zwischen den einzelnen Schritten entstehen keine inkonsistenten Zwischenstände.

5.2 Was weniger gut funktioniert hat

Apache Airflow verursachte mit Abstand den grössten Zeitaufwand im Projekt. Die Einrichtung der DAG-Abhängigkeiten, die korrekte Reihenfolge zwischen ETL-, Feature- und Training-Pipeline sowie die Konfiguration der ExternalTaskSensor-Wartelogik erwiesen sich als unerwartet komplex. Mehrfach mussten DAG-Definitionen vollständig überarbeitet werden, weil sich Backfill-Läufe und Live-Betrieb unterschiedlich verhielten, zum Beispiel bei der Behandlung bereits vorhandener Datensätze in TimescaleDB. Die Fehlersuche in den Airflow-Logs kostete viel Zeit, da bei verschachtelten Task-Fehlern die eigentliche Ursache oft mehrere Ebenen tief im Stack-Trace vergraben war. Insgesamt floss rund ein Drittel der gesamten Projektzeit allein in die Stabilisierung der Pipeline.

LSTM und Transformer schnitten bei beiden Zielgrössen geringfügig schlechter ab als XGBoost, benötigten aber 15–50-fach längere Trainingszeiten. Der Hauptgrund: Für Modell B stehen nur rund 19 000 stündliche Trainingspunkte zur Verfügung, zu wenig, damit Transformer-Modelle ihr Potenzial voll ausschöpfen können.

EKZ-Validierung war zeitweise eingeschränkt, da die EKZ-API undokumentierte Rate-Limits hat (geschätzt 200 Anfragen/Tag). Diese wurden durch unseren API-Aufruf-Logger aufgedeckt. Als

Fallback wurde eine Offline-Validierung auf Basis gespeicherter CSV-Snapshots implementiert.

Hydrodaten des BAFU lieferten keinen messbaren Beitrag zur Modellgüte, weil tagesaktuelle Reservoirpegelstände für eine Day-Ahead-Prognose zu spät vorliegen.

5.3 Limitierungen

- **Geografische Einschränkung:** Die Tarifformeln sind auf den EKZ-Netzbereich Winterthur kalibriert. Für andere Netzbetreiber wäre eine Neukalibrierung notwendig.
- **Datenlücken:** In älteren ENTSO-E-Erzeugungsdaten (vor 2016) fehlen einzelne Werte. Die Median-Auffüllung reicht für den Normalbetrieb, könnte aber bei Extremereignissen besser gelöst werden.
- **Negative Preise:** Wenn viel Sonnen- oder Windstrom ins Netz drängt, können EPEX-Preise negativ werden. Die eingesetzte Begrenzungsfunktion verhindert negative Tarifaufgaben, weicht in diesen Extremsituationen aber systematisch vom echten Marktpreis ab.
- **Einzelner Server:** Das System läuft auf einer einzelnen Workstation ohne Ausfallsicherung. Ein Geräteausfall führt zu fehlenden Prognoseupdates.

6 Verwandte Arbeiten

Strompreisvorhersage. Lago et al. [4] haben über 300 Methoden zur Vorhersage von Day-Ahead-Strompreisen verglichen und gezeigt, dass Gradient-Boostingmethoden neuronalen Netzen und klassischen ARIMA-Modellen häufig überlegen sind. Unser Ansatz geht darüber hinaus: Wir modellieren nicht nur den Börsenpreis, sondern die vollständige Tarifkette bis zum Endkunden.

Statistische Preismodelle. Ziel und Liu [5] nutzen ein LASSO-Modell, das automatisch irrelevante Variablen herausfiltert. XGBoost erfüllt diese Funktion implizit durch seine Baumtiefenbegrenzung, ohne dass ein zusätzlicher Regularisierungsparameter gesetzt werden muss.

Wahrscheinlichkeitslastprognosen. Hong et al. [7] empfehlen Wettervariablen als zentrale Eingrößen für Lastprognosen, ein Ansatz, dem wir bei Modell A folgen. Die Unsicherheitsgrenzen berechnen wir analog als Vorhersageintervall auf Basis des Validierungsfehlers.

Haushalts-Lastprognosen. Haben und Singleton [8] zeigen, dass selbst auf Einzelhaushaltsebene gute Ergebnisse mit einfachen Merkmalen möglich sind. Wir aggregieren auf Gemeindeebene (gesamtes Winterthurer Netz), was die Streuung deutlich reduziert und robustere Vorhersagen ermöglicht.

Zeitreihendatenbanken. TimescaleDB [9] bietet gegenüber spezialisierten Time-Series-Datenbanken wie InfluxDB den Vorteil, dass sich SQL-Fensterfunktionen für komplexe Feature-Berechnungen direkt in der Datenbank ausführen lassen, ohne eine externe Verarbeitungsschicht wie Apache Spark.

7 Fazit und Ausblick

7.1 Fazit

Mit *BigDataSmallPrice* haben wir ein betriebsnahes System zur Prognose dynamischer Stromtarife für Winterthur entwickelt. Die Plattform liest täglich Daten aus acht Quellen ein, erzeugt daraus

Trainingsfeatures, nutzt die besten gespeicherten Modelle und stellt die Ergebnisse über eine REST-Schnittstelle sowie ein interaktives Dashboard bereit. XGBoost erreicht einen MAPE von 3,99 % bei der Lastprognose und 7,72 % bei der Energiepreisvorhersage und liegt damit deutlich unter den angestrebten Grenzen von 8 % und 15 %. Das Dashboard macht die Prognosen für Endnutzer direkt handlungsrelevant: Wer die günstigen Zeitfenster nutzt, kann seinen Stromkosten spürbar senken.

7.2 Ausblick

- **Echtzeit-Daten:** Integration von Stadtwerk-Winterthur-Messwerten über eine Live-Verbindung, um die Prognose im Tagesverlauf laufend zu korrigieren.
- **Weitere Netze:** Ausdehnung auf andere Schweizer Netzbetreiber (St. Gallen, Bern, Zürich), die ebenfalls dynamische Tarife einführen.
- **Automatische Laststeuerung:** Erweiterung um eine Optimierungskomponente, die Lade- und Betriebszeiten von E-Fahrzeugen, Wärmepumpen und Heimspeichern automatisch plant.
- **Bessere Sequenzmodelle:** Vortraining eines grossen Zeitreihen-Transformers (z. B. TimesFM [11]) auf breiten Energiedatensätzen und anschliessendes Fine-Tuning auf Winterthurer Daten.

- **Cloud-Betrieb:** Migration auf eine Hochverfügbarkeitsinfrastruktur für produktiven Betrieb mit garantierter Verfügbarkeit.

Literatur

- [1] ElCom – Eidgenössische Elektrizitätskommission. Dynamische Tarife – Variable Netznutzungsentgelte und Markttöffnung. Technischer Bericht, ElCom, Bern, 2023. <https://www.elcom.admin.ch/>.
- [2] Bundesamt für Strassen ASTRA. Fahrzeugbestand Schweiz 2024 – Elektrofahrzeuge. Technischer Bericht, ASTRA, Bern, 2024. <https://www.astra.admin.ch/>.
- [3] EKZ – Elektrizitätswerke des Kantons Zürich. Dynamische Tarifiedokumentation und API-Spezifikation. Technisches Dokument, EKZ, Zürich, 2024. <https://www.ekz.ch/>.
- [4] J. Lago, G. De Ridder, P. Vrancx, and B. De Schutter. Forecasting day-ahead electricity prices: A review of state-of-the-art algorithms, best practices and an open-access benchmark. *Applied Energy*, 293:116983, 2021.
- [5] F. Ziel and B. Liu. Lasso estimation for GefCom2014 quantile energy forecasting. *International Journal of Forecasting*, 32(3):1029–1037, 2016.
- [6] R. Weron. Electricity price forecasting: A review of the state-of-the-art with a look into the future. *International Journal of Forecasting*, 30(4):1030–1081, 2014.
- [7] T. Hong, P. Pinson, S. Fan, H. Zareipour, A. Troccoli, and R. J. Hyndman. Probabilistic energy forecasting: Global energy forecasting competition 2014 and beyond. *International Journal of Forecasting*, 32(3):896–913, 2016.
- [8] S. Haben and G. Singleton. Decomposition and short-term forecasting of electrical demand and price time series for a local urban network. In *Proceedings of BigData 2013*, pages 39–45. IEEE, 2013.
- [9] F. Freedman, E. Malviya, Y. Liu, A. Ditton, and M. Stonebraker. TimescaleDB: A time-series database for high-performance inserts and complex queries. In *Proceedings of CIDR 2017*, 2017.
- [10] T. Chen and C. Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of KDD '16*, pages 785–794. ACM, 2016.
- [11] A. Das, W. Kong, A. Sen, and Y. Zhou. A decoder-only foundation model for time-series forecasting. In *Proceedings of ICML 2024*, 2024.